Was die Prüfungen tatsächlich absichern

Datenlecks, Unabhängigkeit und Aussagegrenzen
Prüfgegenstand: veröffentlichter RAX-B1-Benchmark
14. Oktober 2026

Gesamtbefund: Zwei Fehler in den Validierungsprüfungen sind reproduzierbar bestätigt. Hinzu kommen eine nachgewiesene Zugriffsgrenze der Messschnittstelle und eine Grenze der Freeze-Selbstauskunft. Die Originaldaten bestehen die strengere Vollständigkeitsprüfung und die vollständige Nachrechnung. Es ergibt sich **kein Anlass, die acht ursprünglichen Hauptentscheidungen zu ändern**: Alle bleiben unentschieden.

ID / Priorität	Befund	Wirkung auf veröffentlichtes B1
M1 / hoch für die Validierung	Negativer Episodenindex ermöglicht doppelte Verwendung einer Zeile trotz PASS.	Im Original nicht vorhanden; 67.584 Zellen vollständig und kanonisch.
M2 / mittel	Der Isolationstest verändert eine unbenutzte Prüfvariable. Ein absichtlich datenabhängiger Planer besteht.	Die volle Referenz weist den getesteten Vorhersageeingriff zurück.
M3 / bedingt mittel	Der Mess-Callback gibt über Introspektion noch nicht erworbene Ergebnisse frei.	Kein solcher Zugriff im eingefrorenen Planer festgestellt. Relevant für fremde Planer.
M4 / niedrig	Freeze meldet keine Testeinsicht, obwohl bereits Testdateien vorliegen.	Die volle Referenz erkennt im Beispiel die falsche Zeitfolge. Kein Beleg früherer Einsicht im Original.

Statistische Gegenbeispiele

Vollständig abhängige Wiederholungen können eine nominelle 95-%-Absicherung auf 0 % tatsächliche Überdeckung reduzieren. Das Aussieben anhand derselben Prüfdaten kann den Brier-Fehler eines unveränderten Vorhersagers von 0,41 auf 0,235534 senken. Diese Beispiele sind mathematisch exakt; sie werden **nicht als nachgewiesene Fehlanwendungen des ursprünglichen B1-Laufs** dargestellt.

Prüfumfang: 36 Dateien gegen das veröffentlichte Archiv abgeglichen, vollständige Originalnachrechnung, gezielte Eingriffe ausschliesslich in Kopien, neun Prüfblöcke, separate Nachrechnung der exakten Beispiele und sechs Testmethoden für Zusatzprüfungen. Interne nachträgliche Prüfung durch denselben Autor; keine externe oder blinde Begutachtung.

M1: Doppelte Episode trotz vollständigem PASS

In reference.py:verify wird episode_index unmittelbar als Python-Listenindex verwendet. Negative Indizes sind dort gültig: -1 bezeichnet das letzte Element. Die Duplikatprüfung verwendet dagegen den unveränderten Index als Schlüssel. Daher gelten (5631, 4, adaptiv) und (-1, 4, adaptiv) als verschieden, obwohl beide dieselbe Episode lesen.

```
ep = episodes[episode_index]  # -1 liest letzte Episode
key = (episode_index, budget, policy)
# Der Bereich 0 <= episode_index < N wird nicht geprüft.
```

Eingriff in eine Kopie des Originaldatensatzes

Die adaptive B=4-Zeile der ersten Beobachtungskontrolle wird durch eine Kopie der letzten Aussenmodell-Episode ersetzt. Deren Index wird von 5631 auf -1 gesetzt. Alle übrigen Werte entsprechen der kopierten Episode. Nur in dieser synthetisch veränderten Kopie werden Dateidigest, Länge und CPU-Summe aktualisiert.

Eigenschaft	Original	Veränderte Kopie
Anzahl Plan-/Budgetzeilen	67.584	67.584
Beobachtungskontrolle, adaptiv B=4	512 Zeilen	511 Zeilen
Aussenmodell, adaptiv B=4	512 Zeilen	513 Zeilen
Bisherige Referenz	PASS	PASS
Bisherige Analyse	COMPLETE	COMPLETE
Zusatzprüfung exakter Zellabdeckung	PASS	Zurückgewiesen: negativer Index

Die acht primären mittleren Differenzen sind in diesem Beispiel unverändert, weil der Eingriff Kontrollfälle betrifft. Er belegt dennoch einen echten Fehler der Vollständigkeitsabnahme: Eine fehlende und eine doppelt verwendete Kontrollzeile werden nicht erkannt.

Zusatzregel und Nachweis

```
if type(i) is not int or not 0 <= i < N:
    raise ValueError('invalid episode index')
expected = set(product(range(N), budgets, policies))
# Prüfe kanonische Identität, Eindeutigkeit und actual == expected.
```

hardened_checks.py enthält diese ergänzenden Regeln. Sie bestehen sämtliche 4.224 Entwicklungs- und 67.584 Testzellen der Originalkampagne. Negative/zu grosse Indizes, boolesche oder nicht ganzzahlige Indizes, Duplikate, fehlende Zellen und falsche Identitäten werden gezielt geprüft.

Beleg: 02_negative_index_alias.json enthält die entfernte und eingefügte Zeile, beide Prüfergebnisse, veränderte Zellzahlen sowie SHA-256-Werte der reproduzierbaren Kopie. Neu erzeugte Prüfsummen testen die inhaltliche Validierung; sie behaupten keinen Angriff auf eine unveränderliche Git-Veröffentlichung.

M2 und M3: Datenleck-Test und Messschnittstelle

M2: Der bisherige Isolationstest ist nicht empfindlich genug

test_exact_budgets_and_holdout_isolation durchläuft zwei Werte einer lokalen Variable unrelated_challenge. Diese wird weder an den Planer übergeben noch mit einer Datenquelle verbunden, die der Planer nutzt. Die verglichenen Aufrufe unterscheiden sich deshalb nicht im wirksamen Prüfdatenzugang.

```
for unrelated_challenge in [zeros(128), ones(128)]:
    result = run_policy(..., measure)
    # unrelated_challenge wird danach nicht verwendet.
```

Der Gegenversuch ersetzt den Planer vorübergehend durch einen Adapter, der seine Vorhersage aus einer verborgenen Prüfdatenquelle übernimmt. Der bestehende Einzeltest führt 48 solche Aufrufe aus und meldet trotzdem OK. Wird dagegen die tatsächlich gelesene Quelle von null auf eins geändert, ändert sich die Vorhersage; der gezielte Zusatzversuch erkennt genau diesen Lecktyp.

Prüfweg	Originalplaner	Absichtlich datenabhängiger Planer
Bisheriger Einzeltest	Besteht	Besteht trotz Leck
Änderung der tatsächlich gelesenen Prüfquelle	Vorhersage unverändert	Vorhersage ändert sich
Volle Referenz auf veränderter Ergebniskopie	Original besteht	Zurückweisung: prediction replay

Folgerung: Das bisherige Test-OK belegt Messbudget und Wiederholbarkeit der getesteten Aufrufe. Es ist kein Nachweis von Prüfdatenisolation. Die zusätzliche vollständige Nachrechnung verhindert im getesteten Beispiel, dass veränderte Vorhersagen unbemerkt als gültige Ergebnisse gelten.

M3: Verdeckte Daten sind im selben Prozess nicht isoliert

Ein zweiter Probeplaner untersucht den tatsächlich von run.acquire erzeugten Callback über __closure__. Er erreicht die Variablen banks, ei und used und liest 64 potentielle Beobachtungen der aktuellen Episode. Zu diesem Zeitpunkt sind null Messungen verbucht; das geplante Messbudget beträgt vier. Die gelesenen Werte stimmen mit der Original-Ergebnisbank überein.

Der Probeversuch wird unmittelbar beendet und erzeugt keine vollständige Kampagne. Der eingefrorene Originalplaner nutzt diese Introspektion nicht; seine beobachteten Aktionen stimmen mit der separaten Referenz überein. Die Schnittstelle ist jedoch ein kooperatives Programmiermodell, keine wirksame Abschottung für fremden Code.

Für austauschbare oder nicht vertrauenswürdige Planer muss der Datenhalter separat kontrolliert werden: keine Ergebnisbank, kein Prüfdaten-Seed und keine Wahrheit im Zugriff des Planerprozesses. Ein zusätzliches Zugriffsprotokoll und veränderte Prüfwelten bleiben nötig; sie sind keine universelle Sicherheitsgarantie. Belege: 03_ineffective_holdout_unit_test.json und 04_callback_future_data.json.

Unabhängigkeit: welche Zahl ist die Stichprobe?

Gezählte Grösse im Original	Wert	Interpretation
Plan-/Budgetzeilen	67.584	Zwölf gepaarte Zeilen je Episode
Testepisoden insgesamt	5.632	Neun Modellbedingungen plus zwei Kontrollen
Primäre Episoden je Kontrast	4.608	Korrekt verwendete Einheit der Hauptintervalle
Akquisition, über alle Läufe summiert	1.013.760	Enthält Wiederverwendung derselben Bankpositionen
Verschiedene verwendete Akquisitionspositionen	235.448	Kein Ersatz für die Zahl unabhängiger Episoden
Verschiedene Prüfpositionen	720.896	128 je Episode, für zwölf Planläufe gemeinsam
Abgeleitete Seed-Domänen	28.832	Keine Kollision; kein Beweis statistischer Unabhängigkeit

Die Originalanalyse behandelt die Messpläne gepaart und verwendet N=4.608 je Hauptkontrast. Die acht Kontraste dürfen untereinander abhängig sein: Bonferroni verwendet eine Vereinigungsabschätzung und benötigt keine Unabhängigkeit zwischen ihnen. Die Hoeffding-Schritte benötigen dagegen die deklarierte Unabhängigkeit zwischen Episoden. Unterschiedliche Seed-Namen beweisen diese Annahme nicht [1].

Exaktes Beispiel A: 512 Zeilen, eine Zufallsquelle

Sei Z eine faire Bernoulli-Variable und $X_1 = \ldots = X_{512} = Z$. Jede Zeile hat Erwartung 1/2, aber alle Zeilen hängen vollständig voneinander ab. Wer sie fälschlich als unabhängig behandelt, erhält einen 95-%-Hoeffding-Radius von 0,060020. Der Mittelwert ist immer null oder eins, also stets 0,5 von der Wahrheit entfernt. Die tatsächliche Überdeckung beträgt exakt **0 %**.

Die zwölfmalige Duplizierung der tatsächlichen B=4-Kontrastwerte lässt ihren Mittelwert unverändert und verkleinert einen naiv berechneten Standardfehler künstlich um den Faktor 3,4644. B1 begeht diesen Fehler nicht; das Beispiel zeigt die Bedeutung seiner Paarungsstruktur.

Exaktes Beispiel B: richtige Randverteilung, falscher Binomialtest

Für eine Aktion seien $Y_1 = \ldots = Y_{64} = Z$ mit P(Z=1)=1/2. Jede Einzelmessung erfüllt die Nullhypothese p=1/2. Die Summe ist aber stets 0 oder 64 und nicht binomialverteilt. Der exakte Binomialtest liefert an beiden Enden den p-Wert 2^{-63} und verwirft immer: **100 % Fehlalarme** statt der vorgesehenen höchstens 0,8333 % je Aktion. Bei unabhängigen Messungen beträgt die exakt berechnete Rate hier 0,814690 % [2].

Diese Konstruktionen sind Annahmen-Stresstests, keine behaupteten Abhängigkeiten der ursprünglichen B1-Daten. Die PRNG-Interpretation und die bedingte Unabhängigkeit des Generators bleiben ausdrücklich Voraussetzungen.

Gemeinsame Prüfdaten und Freeze-Selbstauskunft

Gemeinsame Prüfung ist keine zweite unabhängige Bestätigung

B1 nutzt dieselben 128 Prüfbeobachtungen einer Episode für den Brier-Score und die Kandidatenverwerfung. Beide Prüfungen sind von der Akquisition getrennt; sie sind nicht zwei voneinander unabhängige Datenbelege. Eine nachträgliche Beschränkung der Leistungsanalyse auf „bestandene“ Prüfmengen wäre eine Selektion anhand des Bewertungsdatensatzes [3].

Exaktes Selektionsbeispiel ohne jede Modellverbesserung

Der wahre Prozess ist Bernoulli(1/2), der feste Vorhersager meldet stets q=0,9. Er wird auf 16 unabhängigen Beobachtungen bewertet. Anschliessend werden nur Stichproben behalten, deren Binomialtest gegen q=0,9 bei 0,05/6 nicht verwirft. Das sind genau die Erfolgszahlen 11 bis 16.

Grösse	Exakter Wert / Ergebnis
Wahrscheinlichkeit, eine Prüfmenge zu behalten	6885/65536 = 10,505676 %
Brier vor Selektion	41/100 = 0,410000
Brier auf derselben, selektierten Prüfmenge	10811/45900 = 0,235534
Scheinbare Verbesserung	2002/11475 = 0,174466
Erwarteter Brier auf einer neuen unabhängigen Prüfung	41/100 = 0,410000

Es wurde kein Modell verändert und nichts gelernt. Die günstigere Zahl entsteht ausschliesslich durch Auswahl. B1 behält verworfene Episoden in der Hauptauswertung; diese konkrete Fehlanwendung wurde dort nicht festgestellt. Der Bericht enthält zusätzlich die rein diagnostischen Werte, die ein solches falsches Aussieben im Originaldatensatz ergeben würde. Sie sind keine neuen Leistungsresultate.

M4: test_outcomes_inspected=false wird nicht gemessen

In einer Kopie liegen die vollständigen Testdateien bereits vor. Eine Prüfbeobachtung wird gelesen; danach wird freeze() erneut aufgerufen, nachdem ausschliesslich der kopierte alte Freeze-Vermerk entfernt wurde. Die Funktion läuft erfolgreich und schreibt dennoch test_outcomes_inspected=false.

Die vollständige Referenz weist diese Kopie anschliessend zurück, weil der neue Freeze zeitlich nach dem alten Testbeginn liegt. Ein beigefügter Vorabcheck verhindert bereits den Freeze bei vorhandenen Testartefakten. Die ursprünglichen Zeitstempel sind richtig geordnet. Es gibt damit keinen Befund, dass der Originaltest vor seinem Freeze eingesehen wurde.

Eine Dateiprüfung kann frühere Einsicht ausserhalb des Verzeichnisses oder eine Vorabberechnung mit dem öffentlichen deterministischen Seed nicht ausschliessen. Die Flagge muss als Selbstauskunft bezeichnet werden. Externe Präregistrierung oder Blindprüfung wurden in B1 bereits ausdrücklich nicht beansprucht. Belege: 05_freeze_attestation.json und 07_holdout_selection_bias.json.

Aussagen begrenzen und Prüfregeln ergänzen

Die folgende Tabelle trennt Aussagen des bestehenden Befunds von unzulässigen Weiterinterpretationen. Sie unterstellt nicht, dass jede zurückgewiesene Formulierung im veröffentlichten Bericht steht.

Aussage	Methodisches Urteil
„Adaptiv ist bestätigt überlegen.“	Nicht gestützt. Sämtliche acht vorab festgelegten simultanen Intervalle enthalten null. Die publizierte Schlussfolgerung ist korrekt unentschieden.
„67.584 unabhängige Versuche.“	Falsch als Stichprobeneinheit. Es sind 5.632 Episoden mit zwölf gepaarten Zeilen; die Hauptkontraste nutzen je 4.608. B1 rechnet mit der richtigen Zahl.
„Der Isolationstest beweist keinen Zugriff auf Prüfdaten.“	Nicht belegt. Der konkrete Einzeltest bleibt auch beim getesteten Leck grün. Seine Aussage muss eingeschränkt werden.
„PASS garantiert die vollständige Episode/Budget/Plan-Abdeckung.“	Für den bisherigen Referenzprüfer widerlegt. Der strenge Zusatzprüfer erkennt das Gegenbeispiel; die Originaldaten bestehen ihn.
„Zweite Implementierung ist eine unabhängige Replikation.“	Nicht in personeller oder datenbezogener Hinsicht. Dieselbe Evidenz, dieselbe PRNG-Spezifikation und derselbe Autor.
„Gleiche Messbudgets bedeuten gleiche Gesamtrechenkosten.“	Nicht gestützt. Gleiche Messzahlen und Obergrenzen; Voraberzeugung der Zufallspläne und Datenbanken liegt ausserhalb der Online-Zeitmessung.
„Synthetische Ergebnisse bestätigen physikalische Modelle.“	Nicht gestützt. Kein neuer U2-Lauf und keine physikalischen Messdaten in dieser Prüfung.

Konkrete Folgerungen nach Priorität

1. Vor weiterer automatisierter Abnahme: Indexbereich/-typ und exakte kartesische Zellabdeckung prüfen. Der ausführbare Zusatzprüfer liegt bei und wurde gegen Original und Gegenbeispiele getestet. Er verändert keine eingefrorenen B1-Dateien.

2. Vor der nächsten Datenleck-Abnahme: Die tatsächlich zugängliche Prüfdatenquelle variieren und absichtlich datenabhängige Testplaner einsetzen. Wiederholbarkeit allein genügt nicht. Die nachgerechneten Aktions- und Posteriorregeln beibehalten.

3. Vor fremden Planern: Datenhalter und Planerausführung mit einer wirksamen Zugriffstrennung betreiben. Der vorliegende Callback soll nicht als Sandbox bezeichnet werden. Diese Prozessarchitektur wurde hier nicht implementiert oder zertifiziert.

4. Für weitere statistische Läufe: Episodenpaarung und Datentrennung bewahren; keine Prüfung bestandener Teilmengen als neue unverzerrte Leistung berichten. Bei realen korrelierten Daten die unabhängige Einheit vorab definieren. Änderungen der Bestätigungskriterien erfordern eine neue Kampagne.

Die Methodenprüfung liefert eine Ergänzung und Korrektur der Prüfinterpretation. Sie wertet die ursprünglichen unentschiedenen Ergebnisse weder zu einem Erfolg noch zu einem Misserfolg um.

Belegkette, Reproduktion und Quellen

Geprüfte Veröffentlichung

GitHub-Commit: 564f694378c8429e40b51e67c6fd437b5a6c8a99
B1-Quell-Freeze: 1ecbda74df9a332a623c5b41d8800f06a503733f
B1-Ergebnisstand: 7acb0733e625502dc5f80b5056e1fa4f18a389d0
Kampagne der Methodenprüfung: RAX-M1-20261014-001

Veröffentlichter B1-Archivdigest (SHA-256):
26609c78549be636b770196ca18d8185a8d072c47606726b71d6bda2a81f7d7f

Alle 36 Benchmarkdateien wurden mit dem Inhalt dieses Archivs verglichen. Vor und nach den Gegenversuchen blieben ihre SHA-256-Werte gleich. Die Rohdaten wurden vollständig erneut nachgerechnet. Die semantische Zusatzprüfung bestätigt sämtliche Zellen beider Originalpartitionen. Alle Angriffe erfolgten auf temporären Kopien oder vorübergehend ersetzten Funktionsbindungen und wurden zurückgenommen.

Lieferumfang und Befehle

Das Belegpaket enthält den unveränderten veröffentlichten B1-ZIP als Basis, Methodenvertrag, ausführbare Gegenbeispiele, ergänzende Prüfregeln, sämtliche Ergebnis-JSONs, die separate Beispielsprüfung, diesen Bericht und ein SHA-256-Inventar. Die grossen veränderten Kopien werden aus den dokumentierten Rezepten regeneriert; relevante ersetzte Einzelzeilen und Digests sind mitgeliefert.

```
python verify_package.py
python reproduce.py --workdir ../new-reproduction
```

Der Zielordner muss neu sein. Der Einstieg prüft das Basisarchiv, entpackt es sicher, führt die neun Auditblöcke aus und prüft die mathematischen Beispiele sowie die Zusatzregeln erneut. Benötigt: Linux/POSIX, Git, Python 3.12.14, NumPy 2.3.5 und SciPy 1.17.0. Ein lokaler Reproduktions-Checkout wird angelegt; es erfolgt kein Upload. Zeitstempel und Laufzeiten variieren; die Befunde und exakten Werte sind reproduzierbar. Die erneute Ausführung ist eine Nachrechnung, keine neue Bestätigungskampagne.

Die exakten statistischen Beispiele wurden zusätzlich ohne Import des ursprünglichen Planers oder Binomialprüfers gegen SciPy-Gates und rationale Summen gerechnet. Sechs gezielte Testmethoden für die Zusatzregeln bestanden. Diese zweite Rechenstrecke stammt ebenfalls vom selben Autor.

Methodische Primärquellen

[1] Hoeffding, W. (1963). Probability Inequalities for Sums of Bounded Random Variables. JASA 58(301), 13-30. Voraussetzungen der verwendeten Konzentrationsabschätzung.
doi:10.1080/01621459.1963.10500830

[2] SciPy, Binomial Distribution, offizielle Dokumentation. Die Binomialverteilung beschreibt die Summe unabhängiger Bernoulli-Versuche. Die Prüfung selbst verwendete die installierte SciPy-Version 1.17.0.
docs.scipy.org/doc/scipy/tutorial/stats/discrete_binom.html

[3] Dwork, C.; Feldman, V.; Hardt, M.; Pitassi, T.; Reingold, O.; Roth, A. (2015). Generalization in Adaptive Data Analysis and Holdout Reuse. NeurIPS 28. Hintergrund zur adaptiven Wiederverwendung von Prüfdaten; hier kein Einsatz oder Nachweis des dortigen Verfahrens.
NeurIPS 2015: Generalization and Holdout Reuse

Die Programmfehler und Zahlen dieses Berichts beruhen auf den mitgelieferten eigenen Reproduktionen. Die Fachquellen begründen die methodischen Voraussetzungen; sie bestätigen nicht die konkrete Software. Der frühere U1-Archivvorfall wird nicht neu diagnostiziert, und Stromausfallsicherheit wird nicht beansprucht.